

BC03 — Modèles supervisés SMOTE, LightGBM & seuil de décision

De la régression logistique de référence au Gradient Boosting : ce que trois configurations de modèle, évaluées sur un split temporel strict, révèlent sur le rééquilibrage des classes et le choix du seuil de décision.

Bloc de compétences : BC03 — Modèles supervisés

Source : socle BC01/BC02 — `dwh.fact_transactions` (voie batch)

Split : temporel 80/20 — train jusqu'au 19/10/2025, test au-delà

Document : note de modélisation et guide de lecture des résultats

Sommaire

1. Objectif du bloc BC03
2. Argumentaire méthodologique
3. Trois configurations, un même protocole
4. Résultats comparés
5. L'effet de SMOTE sur la régression logistique
6. Optimisation du seuil de décision

7. Importance des variables et limites de lecture

8. Synthèse et implications pour le BC04

1. Objectif du bloc BC03

Le BCo2 a mesuré, chiffres à l'appui, la limite d'une détection fondée sur une seule variable à la fois : au mieux 30 % de rappel, parce que la fraude simulée porte six signatures différentes qu'aucune variable isolée ne peut toutes capturer. Le BCo3 répond directement à cette limite en entraînant des modèles capables de combiner plusieurs variables simultanément. Il poursuit trois objectifs concrets : établir une référence simple et interprétable (Logistic Regression), mesurer l'effet réel d'une technique de rééquilibrage des classes (SMOTE) plutôt que de le supposer bénéfique par principe, puis évaluer un modèle non linéaire plus expressif (Gradient Boosting via LightGBM) et déterminer le seuil de décision qui exploite au mieux ses prédictions.

2. Argumentaire méthodologique

Le découpage entre données d'entraînement et données de test suit une logique **temporelle**, et non un tirage aléatoire : les 320 000 premières transactions chronologiques (jusqu'au 19 octobre 2025) servent à l'entraînement, les 80 000 suivantes à l'évaluation. Un tirage aléatoire classique aurait mélangé des transactions futures dans l'entraînement et des transactions passées dans le test, une forme de fuite d'information qui surestime systématiquement la performance mesurée par rapport à un déploiement réel, où le modèle ne voit jamais que le passé. Le taux de fraude reste stable entre les deux ensembles (1,49 % en train, 1,53 % en test), ce qui confirme que le split ne biaise pas la comparaison.

Une variable identifiée au BCo2 est délibérément exclue du jeu de features : `pays_transaction` (et son écart au pays de résidence). Ce couple s'est révélé être un séparateur parfait — 100 % de fraude dès que le pays diffère —, mais ce résultat est un artefact de la génération synthétique du BCo1, pas un signal représentatif d'un cas réel. L'inclure donnerait un modèle artificiellement parfait sur ces données précises, sans aucune valeur démonstrative ni transférable. Cette exclusion est documentée ici précisément pour que le choix soit traçable, et non pour dissimuler une variable gênante.

Deux métriques structurent la lecture des résultats en plus de l'AUC-ROC habituelle : le **Gini** ($2 \times \text{AUC} - 1$, une transformation directe de l'AUC-ROC, seuil de référence Bâle III à 0,65) et l'**average precision** (aire sous la courbe précision/rappel). Cette dernière est cruciale ici : sous un déséquilibre de 1,5 %, l'AUC-ROC reste presque saturée pour les trois modèles (0,983 à 0,998) et masque des écarts de performance réels — la section 4 le montre numériquement.

3. Trois configurations, un même protocole

Les trois modèles partagent exactement le même jeu de variables (montant, distance au domicile, revenu mensuel, heure, jour de la semaine, mois, week-end, nuit, authentification, canal, segment) et le même prétraitement (mise à l'échelle des variables numériques, encodage one-hot des variables

catégorielles), afin que seule la stratégie de modélisation diffère d'une configuration à l'autre.

CONFIGURATION	GESTION DU DÉSÉQUILIBRE	PRINCIPE
Logistic Regression	Aucune	Référence linéaire, sans intervention sur les classes
Logistic Regression + SMOTE	SMOTE, 30 % de la classe majoritaire	Sur-échantillonnage synthétique de la fraude, train uniquement
LightGBM	<code>scale_pos_weight</code> ≈ 66	Repondération native du gradient boosting, pas de SMOTE

Pourquoi ne pas appliquer SMOTE au LightGBM aussi ? Un arbre de décision découpe l'espace des variables en régions ; il tire peu de bénéfice d'un point synthétique interpolé entre deux voisins, qui tombe presque toujours dans une région déjà bien caractérisée par les points réels. À l'inverse, une repondération native (`scale_pos_weight`) agit directement sur la fonction de perte à chaque itération de boosting, sans déformer la distribution des données. SMOTE est réservé ici au modèle linéaire, pour lequel son effet est démontré en section 5 — chaque technique est appliquée là où elle a un fondement, pas de façon uniforme.

4. Résultats comparés

Les trois courbes ROC se superposent presque parfaitement (AUC de 0,983 à 0,998) — un artefact classique du déséquilibre extrême, où le taux de faux positifs reste mécaniquement bas même pour un modèle médiocre, simplement parce que la classe négative est écrasante. La courbe précision/rappel raconte une tout autre histoire : LightGBM atteint une *average precision* de 0,921, contre 0,670 pour la régression logistique seule et seulement 0,605 avec SMOTE. C'est cet écart-là qui reflète la performance réellement exploitable en production.




Figure 1 — Courbe ROC (les trois modèles se ressemblent) et courbe Précision/Rappel (LightGBM se détache nettement).

MODÈLE	AUC-ROC	GINI	AVG. PRECISION	PRÉCISION @0,5	RAPPEL @0,5	F1 @0,5
Logistic Regression	0,983	0,967	0,670	80,0 %	45,5 %	0,580
Logistic Regression + SMOTE	0,984	0,968	0,605	23,4 %	86,6 %	0,368
LightGBM	0,998	0,997	0,921	60,9 %	96,6 %	0,747

Lecture. Le Gini de LightGBM (0,997) dépasse très largement le seuil de 0,65 exigé par Bâle III pour un score de risque bancaire ; celui de la régression logistique (0,967) le dépasse également, ce qui confirme que le Gini seul, ici encore comme l'AUC-ROC, ne suffit pas à départager les modèles sous un tel déséquilibre — l'average precision reste le juge de paix.

5. L'effet de SMOTE sur la régression logistique

Appliqué à la régression logistique, SMOTE produit exactement l'effet attendu en théorie : le rappel bondit de 45,5 % à 86,6 % — le modèle détecte presque deux fois plus de fraudes. Mais ce gain a un coût sévère : la précision s'effondre de 80,0 % à 23,4 %, si bien que le F1, qui résume les deux, **baisse** au lieu d'augmenter (0,580 → 0,368). SMOTE n'est donc pas une amélioration inconditionnelle : il déplace la frontière de décision vers la classe minoritaire, ce qui profite au rappel mais peut dégrader la précision plus qu'il ne compense — exactement ce que montre ce résultat, plutôt que de l'affirmer sans preuve.




Figure 2 — SMOTE augmente le rappel mais fait chuter la précision : le F1 recule.

Point de vigilance. Ce résultat ne signifie pas que SMOTE est une mauvaise technique en général — il signifie qu'elle n'est pas systématiquement bénéfique, et que son effet doit être mesuré sur le cas d'usage réel plutôt que présumé. Sur un modèle déjà capable de bien séparer les classes (ici la régression logistique atteint 80 % de précision sans intervention), forcer un rééquilibrage supplémentaire peut faire plus de mal que de bien.

6. Optimisation du seuil de décision

Un modèle de classification ne produit pas une décision binaire mais une probabilité ; le seuil au-delà duquel on la convertit en alerte est un choix distinct de l'entraînement du modèle. Au seuil par défaut de 0,50, LightGBM détecte 96,6 % des fraudes mais ne les concentre qu'à 60,9 % de précision — 758 fausses alertes pour 1 180 vraies fraudes détectées sur les 80 000 transactions de test. En balayant systématiquement les seuils de 0,01 à 0,99 et en retenant celui qui maximise le F1, le seuil optimal se situe à **0,98** : la précision grimpe à 88,5 %, au prix d'un rappel ramené à 76,8 % (938 fraudes détectées, 283 manquées, mais seulement 122 fausses alertes).




Figure 3 — Précision, rappel et F1 selon le seuil ; le F1 est maximal juste avant le décrochage du rappel.




Figure 4 — Le seuil optimisé réduit les fausses alertes de 758 à 122, au prix de fraudes manquées passant de 41 à 283.

Le F1 n'est pas neutre. Optimiser le seuil pour maximiser le F1 traite une fraude manquée et une fausse alerte comme équivalentes. Or le contexte réglementaire posé en introduction du projet impose un remboursement client sous 24h en cas de fraude avérée : le coût d'une fraude manquée (perte financière directe, remboursement) dépasse en général très largement celui d'une fausse alerte (une vérification client). Un seuil optimisé sur un coût métier explicite — pas seulement sur le F1 — serait probablement inférieur à 0,98 en production. Ce choix final relève d'une décision métier, formalisée au BC06, et non d'un optimum purement statistique.

7. Importance des variables et limites de lecture

Le montant, la distance au domicile et le revenu mensuel net dominent le classement d'importance de LightGBM, loin devant les variables catégorielles (canal, authentification, segment). Cette hiérarchie doit être lue avec précaution : l'importance par gain de LightGBM favorise structurellement les variables numériques continues, qui offrent davantage de points de coupure possibles à chaque arbre, au détriment des variables encodées en one-hot, dont l'importance se fragmente entre plusieurs colonnes binaires. Le canal `en_ligne` et l'absence d'authentification, identifiés comme fortement discriminants au BCO2 (taux de fraude de 2,43 % et 5,56 % respectivement), apparaissent ainsi moins bien classés ici qu'une lecture univariée ne le laisserait supposer — un écart méthodologique à garder en tête plutôt qu'une contradiction entre les deux blocs.




Figure 5 — Importance par gain LightGBM : les variables continues dominent, un biais connu de cette métrique.

8. Synthèse et implications pour le BC04

Trois conclusions structurent la suite du projet. D'abord, un modèle non linéaire capable de combiner les variables (LightGBM) apporte un gain net et mesuré par rapport à un modèle linéaire — l'average precision passe de 0,670 à 0,921 —, validant l'hypothèse posée en synthèse du BCO2 selon laquelle la fraude multi-signature exige une combinaison de variables plutôt qu'une règle isolée.

Ensuite, ni le rééquilibrage des classes ni le choix du modèle ne dispensent d'une décision explicite sur le seuil : deux modèles avec un excellent AUC peuvent avoir des comportements opérationnels radicalement différents selon où l'on place la frontière de décision, et ce choix engage un arbitrage métier, pas seulement statistique. Enfin, le modèle retenu ici (LightGBM, [bc03_modeles_supervises/models/modele_lightgbm.joblib](#)) reste un modèle à base d'arbres sur des variables tabulaires classiques : le BCo4 explorera des approches complémentaires — autoencodeur pour la détection d'anomalies sans label, réseau de neurones sur des séquences de transactions — capables de capturer des dépendances temporelles qu'un modèle par transaction indépendante, comme ceux de ce bloc, ne voit structurellement pas.